

2.3 — Persistencia y Análisis de Datos

Tema 1 – Persistencia Relacional





Índice



- Introducción
- JPA e Hibernate
- Mapeo en Hibernate
- Relaciones entre entidades
- Herencia
- Fetching y eficiencia
- Gestión de concurrencia

Bibliografía



- Martin Fowler (2002). Patterns of Enterprise Application Architecture. Published by Addison-Wesley Professional.
- Merrick Schincariol; Mike Keith; Massimo Nardone (2018). Pro JPA 2 in Java EE 8: An In-Depth Guide to Java Persistence APIs. Published by Apress.
- Vlad Mihalcea (2019). High-Performance Java Persistence. Get the most out of your persistence layer. LeanPub.



Objetos vs tablas (impedance mismatch)

- Las bases de datos relacionales almacenan los datos en tablas.
- Los datos en un programa son objetos.
 - Contienen estado y comportamiento.
 - Admiten relaciones bidireccionales.
- El esquema de base de datos se gestiona a través de SQL.
- Un modelo orientado a objetos se debe adaptar al esquema de base de datos y a la comunicación SQL.



- El mapeo objeto-relacional (ORM, Object-Relational Mapping), ayuda a comunicar ambas representaciones (esquema vs objetos) haciendo que el salto de tecnologías sea transparente.
- Cada fila de la BD se mapea a un objeto.
 - En terminología JPA esos objetos son entidades.
- ORM traduce transiciones de estado de las entidades a comandos SQL.



JPA (Java Persistence API):

- Estándar de Java EE para persistencia.
- Especificación de interfaces a implementar y de metadatos para ORM.

• Hibernate:

- Implementación ORM en Java, nació antes que JPA.
- Implementa tanto el estándar JPA como su API previa para retrocompatibilidad.
- Proporciona características nativas no JPA que son relevantes para conseguir eficiencia.
- http://hibernate.org





Spring Data

- Capa de persistencia de Spring.
- Se puede usar con cualquier base de datos (relacional o NoSQL).
- Utiliza Hibernate para las bases de datos relacionales.
- Proporciona métodos para carga y almacenamiento de datos.
- Implementa métodos de consulta a partir de los nombres declarados en los repositorios.
 - Los métodos pueden tener varios parámetros que forman expresiones lógicas: Y, O, No...
- Los métodos se pueden anotar para definir la consulta de forma más precisa con Java Persistence Query Language (JPQL).
- http://docs.spring.io/spring-data/jpa/docs/current/reference/html/



- JPA no se define en términos de comandos SQL sino de transiciones de estado de las entidades.
- El EntityManager es el interfaz que define las operaciones de persistencia.
 - Se delega en su implementación el trabajo real de persistencia.
- El conjunto de entidades manejadas por el EntityManager se denomina contexto de persistencia.
 - El contexto de persistencia detecta los cambios de estado en las entidades y los traduce a comandos SQL en el flushing.
- EntityManager de JPA y Session de Hibernate canalizan las operaciones sobre el contexto de persistencia.
 - Definen todas las transiciones de estado de las entidades.



- Una entidad puede estar en uno de los siguientes estados:
 - New (Transient): entidad creada pero no mapeada a ninguna fila de la BD.
 - Cuando se convierte en *managed*, el contexto de persistencia genera un comando *insert*.
 - Managed (Persistent): una entidad persistente se corresponde con una fila de la BD, y está gestionada (managed) por el contexto de persistencia.
 - Los cambios se transmiten a la BD con comandos update.
 - Detached: si el contexto de persistencia se cierra, las entidades se desvinculan de la BD y no se producen actualizaciones.
 - Removed: una entidad sobre la que se ha ejecutado un comando delete.



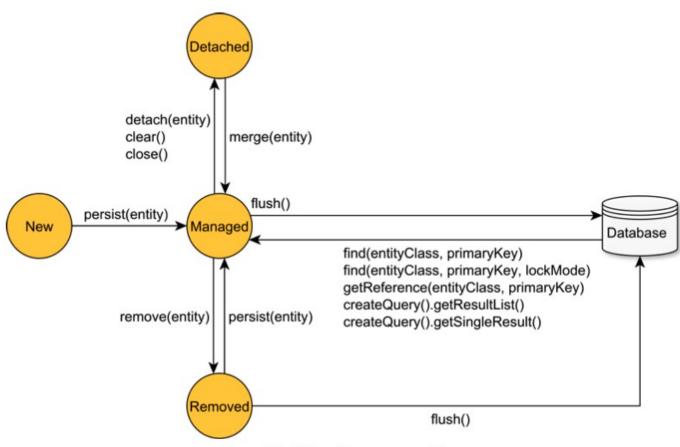


Figure 7.4: JPA entity state transitions

Fuente: Vlad Mihalcea (2019). High-Performance Java Persistence.



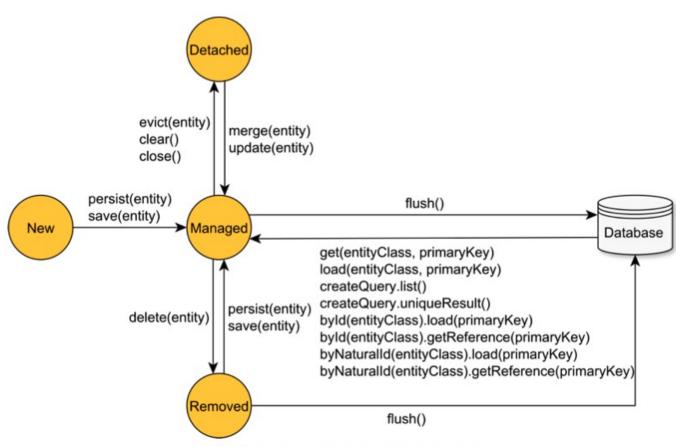


Figure 7.5: Hibernate entity state transitions

Fuente: Vlad Mihalcea (2019). High-Performance Java Persistence.

Mapeo en Hibernate



- Una entidad que se compone de atributos simples se transforma en una fila de una tabla.
- JPA maneja tres tipos de mapeo: type, embedded y entity.
- A nivel de tipo (type), Hibernate realiza el mapeo entre los tipos
 JDBC (aplicados en el driver de la BD) y los tipos de Java.
 - Los tipos primitivos (int, char, ...) solamente se mapean a columnas NOT NULL. Para columnas que admiten NULL se deben utilizar los wrappers (Integer, Char, ...)
 - Las fechas son complicadas: horarios de verano e invierno, decalajes (leap seconds), ...
 - Se suelen guardar los datos en UTC y transformar a la zona horaria en la capa de datos.

Mapeo en Hibernate



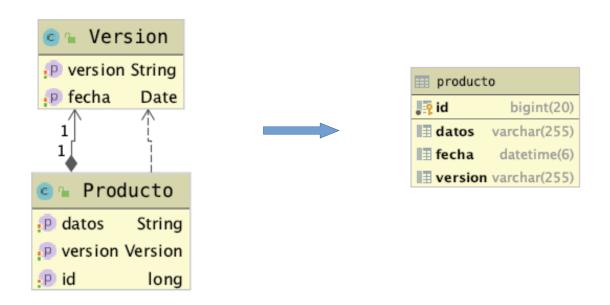
- El mapeo embedded se corresponde con la composición de objetos:
 - Si una entidad incluye un objeto embeddable, entonces sus atributos se añaden como columnas a la tabla que representa la entidad.
- Los objetos incrustados:
 - Se anotan con la etiqueta @Embeddable.
 - No pueden tener identificador (clave), porque provocaría que cada entidad tuviese varios identificadores.
 - Tiene estado, pero se controla por la entidad "padre", no por el contexto de persistencia.





Ejemplo:

- Producto es la entidad padre.
- Version es un objeto incrustado.



Mapeo en Hibernate



Ejemplo:

Entidad padre

```
@Entity
public class Producto {
    @Id
    @GeneratedValue(strategy = GenerationType.AUTO)
    private long id;
    // Por ejemplo, marca y modelo
    private String datos;
    private Version version;
    public Producto() { }
}
```

Mapeo en Hibernate



Ejemplo:

Objeto incrustado

```
@Embeddable
public class Version {

    private String version;
    private Date fecha;

    public Version() {}

    public Version(String version, Date fecha) {
        this.version = version;
        this.fecha = fecha;
    }

    // Getters y setters
...
}
```

Código en GitHub:

Relaciones entre entidades



- El mapeo entity se corresponde con la asociación de entidades.
- En el modelo relacional hay tres tipos de relaciones:
 - Uno a uno (1:1)
 - Uno a muchos (1:N)
 - Muchos a muchos (N:M)
- Desde el punto de vista del esquema, las entidades se traducen a tablas y las relaciones a claves ajenas.
- Estas relaciones se mapean en Hibernate de dos maneras:
 - Unidireccional: solamente una entidad (principal) tiene referencia a la otra.
 - Bidireccional: desde ambas entidades se accede a la asociada.
 - Se utilizan las anotaciones @OneToOne, @OneToMany, @ManyToOne y @ManyToMany
- Se puede utilizar *cascade* para no tener que guardar las dos entidades de la relación explícitamente a través de los repositorios. Basta con guardar la principal.

Relaciones entre entidades



- Las relaciones entre entidades también sirven para recuperar datos.
- Al recuperar datos de la BD existen dos opciones:
 - Eager fetch: carga "ansiosa", recupera también las entidades asociadas en una relación.
 - Puede afectar al rendimiento si hay muchas entidades relacionadas y tienen gran anchura.

```
@OneToMany(fetch = FetchType.EAGER)
```

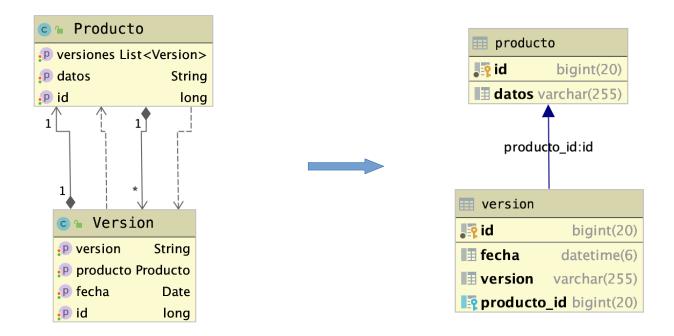
- Lazy fetch: carga perezosa, no recupera entidades asociadas.
- Por defecto, desde JPA 2.0 el fetch type es LAZY.
 - Mejor para rendimiento.





Ejemplo: OneToMany

Un Producto puede tener varias Versiones (1:N)



Código en GitHub:





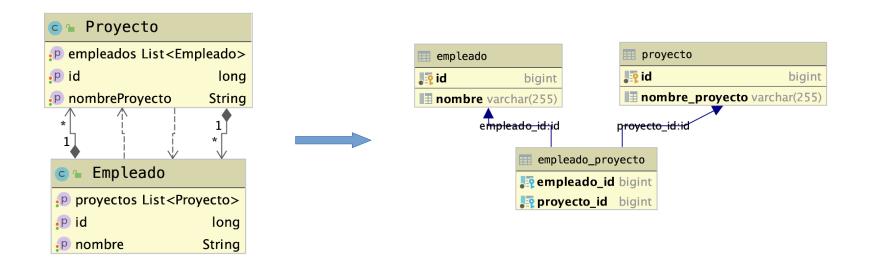
- Las relaciones N:M (muchos a muchos) son las más complicadas de gestionar.
 - Una entidad A se relaciona con varias B y viceversa.
 - Implica tener una nueva tabla para almacenar las parejas de relaciones.
- Hibernate infiere la creación de una nueva tabla a partir de las anotaciones @ManyToMany.
- Existen algunos inconvenientes de rendimiento.

Relaciones entre entidades



Ejemplo: ManyToMany

 Un Empleado trabaja en varios Proyectos y un Proyecto tiene varios Empleados.



Código en GitHub:





Ejemplo: ManyToMany

- El código SQL que se genera al añadir elementos es el que se espera: instrucciones insert para todas las tablas.
- Sin embargo, al eliminar el vínculo entre dos elementos, el comportamiento es diferente: borra todos los vínculos y después restaura.

```
// Guardando datos ...
Empleado e1 = new Empleado("Juan");
Proyecto p1 = new Proyecto("Proy 1");
Proyecto p2 = new Proyecto("Proy 2");
Proyecto p3 = new Proyecto("Proy 3");

List<Proyecto> proyectos = new ArrayList<>();
proyectos.add(p1);
proyectos.add(p2);
proyectos.add(p3);
e1.setProyectos(proyectos)
empleadoRepository.save(e1);

// Borrado de datos
e1.getProyectos().remove(p2);
empleadoRepository.save(e1);
```

Relaciones entre entidades



Ejemplo: ManyToMany

- El código SQL que se genera al añadir elementos es el que se espera: instrucciones insert para todas las tablas.
- Sin embargo, al eliminar el vínculo entre dos elementos, el comportamiento es diferente: borra todos los vínculos y después restaura.

```
// Inserción
insert into empleado (nombre, id) values (?, ?)
insert into proyecto (nombre proyecto, id) values (?, ?)
insert into proyecto (nombre proyecto, id) values (?, ?)
insert into proyecto (nombre proyecto, id) values (?, ?)
insert into empleado proyecto (empleado id, proyecto id) values (?, ?)
insert into empleado proyecto (empleado id, proyecto id) values (?, ?)
insert into empleado proyecto (empleado id, proyecto id) values (?, ?)
// Borrado:
select empleado0 .id as id1 0 1 , empleado0 .nombre as nombre2 0 1 ,
proyectos1 .empleado id as empleado1 1 3 , proyecto2 .id as proyecto2 1 3 ,
proyecto2 .id as id1 2 0 , proyecto2 .nombre proyecto as nombre p2 2 0 from
empleado empleado0 left outer join empleado proyecto proyectos1 on
empleado0 .id=proyectos1 .empleado id left outer join proyecto proyecto2 on
proyectos 1 .proyecto id=proyecto2 .id where empleado0 .id=?
delete from empleado proyecto where empleado id=?
insert into empleado proyecto (empleado id, proyecto id) values (?, ?)
insert into empleado proyecto (empleado id, proyecto id) values (?, ?)
```





Ejemplo: ManyToMany

 Si se invierte el orden de los proyectos asociados al empleado pasa lo mismo!!

```
// Inversión de los datos
el.getProyectos().sort(Collections.reverseOrder(Comparator.comparing(Proyecto::getId)));
empleadoRepository.save(el);
```



```
select empleado0_.id as id1_0_1_, empleado0_.nombre as nombre2_0_1_, proyectos1_.empleado_id as empleado1_1_3_, proyecto2_.id as proyecto2_1_3_, proyecto2_.id as id1_2_0_, proyecto2_.nombre_proyecto as nombre_p2_2_0_ from empleado empleado0_ left outer join empleado_proyecto proyectos1_ on empleado0_.id=proyectos1_.empleado_id left outer join proyecto proyecto2_ on proyectos1_.proyecto_id=proyecto2_.id where empleado0_.id=? select proyecto0_.id as id1_2_0_, proyecto0_.nombre_proyecto as nombre_p2_2_0_ from proyecto proyecto0_ where proyecto0_.id=? delete from empleado_proyecto where empleado_id=? insert into empleado_proyecto (empleado_id, proyecto_id) values (?, ?) insert into empleado_proyecto (empleado_id, proyecto_id) values (?, ?)
```





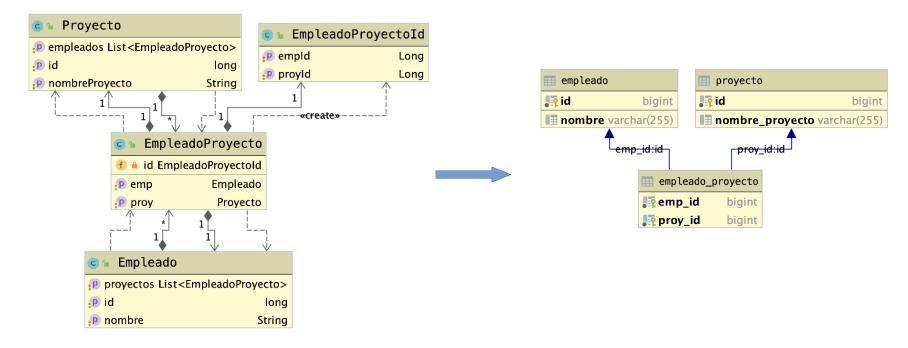
- Para mejorar el rendimiento se puede optar por una aproximación tipo 1:N.
 - Una relación N:M se compone de dos relaciones 1:N a nivel de tablas.
- Se necesita una clave compuesta por los IDs de las entidades a relacionar.
 - Es necesario un @Embeddable (que debe implementar el interfaz Serializable).
- Se utiliza el lado del hijo para realizar las operaciones con peor rendimiento "por defecto".





Ejemplo: ManyToMany **optimizado**.

Un Empleado trabaja en varios Proyectos y un Proyecto tiene varios Empleados.



Código en GitHub:

Relaciones entre entidades



Ejemplo: ManyToMany **optimizado**.

```
// Guardando datos ...
Empleado e1 = new Empleado("Juan");
Proyecto p1 = new Proyecto("Proy 1");
Provecto p2 = new Provecto("Prov 2");
Proyecto p3 = new Proyecto("Proy 3");
List<EmpleadoProyecto> rels = new ArrayList<>();
EmpleadoProyecto e1p1 = new EmpleadoProyecto(e1,p1);
EmpleadoProyecto e1p2 = new EmpleadoProyecto(e1,p2);
EmpleadoProyecto e1p3 = new EmpleadoProyecto(e1,p3);
rels.add(e1p1); rels.add(e1p2); rels.add(e1p3);
e1.setProyectos(rels);
empleadoRepository.save(e1);
// Se puede borrar el dato directamente tras desvincularlo
e1p2.getEmp().getProyectos().remove(e1p2);
e1p2.getProy().getEmpleados().remove(e1p2);
e1p2.setEmp(null);
e1p2.setProy(null);
empleadoProyectoRepository.delete(e1p2);
```

delete from empleado proyecto where emp id=? and proy id=?

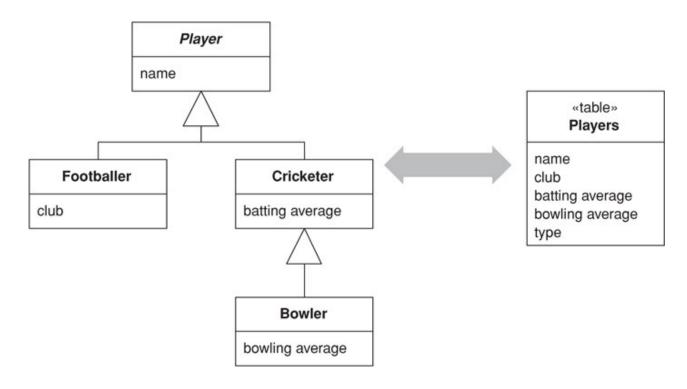


- La herencia es una característica fundamental de la POO.
- Si el ORM ya es un problema en sí, incorporar la herencia lo complica aún más.
- Aunque el estándar SQL99 incorpora herencia de tipos, esta característica rara vez se implementa en SGBDs.
 - Si no hay soporte del SGBD se deben buscar alternativas.
- La herencia se implementa a través de relaciones entre tablas (claves ajenas).
- Martin Fowler define tres modos de implementación de herencia en BBDD relacionales en su libro Patterns of Enterprise Application Architecture:
 - Single Table Inheritance
 - Class Table Inheritance
 - Concrete Table Inheritance
- No es necesario aplicar el mismo patrón de herencia a todas las clases.



Single Table Inheritance:

Utiliza una sola tabla para mapear todas las clases en una jerarquía.



Fuente: Martin Fowler (2002). Patterns of Enterprise Application Architecture.



Single Table Inheritance:

 En JPA es la estrategia por defecto, pero se puede indicar explícitamente como

```
InheritanceType.SINGLE TABLE.
```

- Hay un campo en la tabla que indica la clase (type) del dato almacenado en la fila.
- Los campos no relevantes quedan a null.
- Al leer los datos hay que saber qué clase cargar.
- La escritura la hace la superclase de la jerarquía.



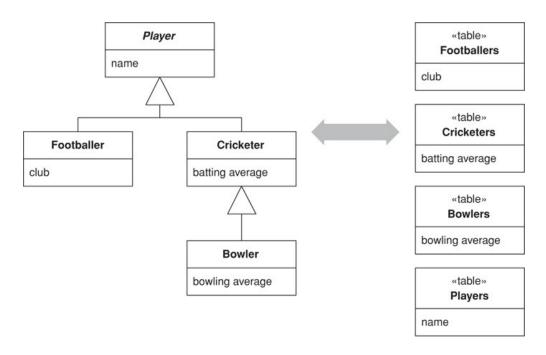
Single Table Inheritance:

- Ventajas:
 - Solamente hay una tabla. No habrá joins entre miembros de la jerarquía.
 - Permite consultas polimórficas.
 - Cualquier refactorización de la jerarquía no altera la BD.
- Inconvenientes:
 - Pérdida de semántica de la jerarquía en la BD.
 - Puede generar una tabla muy ancha y con campos vacíos.
 - Si hay campos con nombres similares en diferentes subclases puede introducir confusión. Se recomienda usar como prefijo del nombre del campo el nombre de la subclase.



Class Table Inheritance:

 Mapea cada clase a una tabla y gestiona la herencia con asociaciones entre tablas (claves ajenas).



Fuente: Martin Fowler (2002). Patterns of Enterprise Application Architecture.



Class Table Inheritance:

- En JPA se indica con @Inheritance(strategy = InheritanceType.JOINED) en la clase madre.
- Una posible implementación es utilizar el mismo id en las filas de las clases hija y padre.
 - Además la clave primaria de la tabla hija es también clave ajena hacia la madre.
 - No se producen conflictos.
 - La alternativa es que las clases hijas tengan su propia id.
- Rendimiento: al guardar un objeto se realizan dos operaciones insert: una en la tabla madre y otra en la hija.
 - Si la herencia es más profunda, implica más insert.



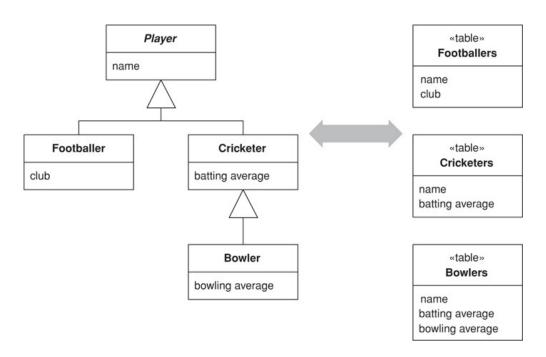
Class Table Inheritance:

- Ventajas:
 - Todas las columnas son relevantes en las tablas, sin desperdicio de espacio.
 - No hay pérdida de semántica.
- Inconvenientes:
 - La recuperación de datos siempre implica un join.
 - La refactorización de campos hacia arriba o abajo de la jerarquía siempre implica cambios en la BD.
 - Las tablas madre son cuellos de botella por los accesos que reciben.
 - Si hay gran normalización, las consultas pueden ser complejas.



Concrete Table Inheritance:

 Mapea cada clase hija a una tabla, propagando hacia abajo los campos de la parte superior de la jerarquía.



Fuente: Martin Fowler (2002). Patterns of Enterprise Application Architecture.



Concrete Table Inheritance:

- En JPA se indica con @Inheritance(strategy = InheritanceType.TABLE_PER_CLASS) en la clase madre.
- Es importante que los *id* de las filas en la herencia sean diferentes a lo largo de la jerarquía.
 - Hibernate lo consigue con hibernate sequence.
 - Si no se puede conseguir, se recomienda utilizar claves compuestas que incluyan el nombre de la tabla (clase).
- Las escrituras son más rápidas que en class table inheritance, pero las lecturas solamente son eficientes si se realizan sobre las subclases.
 - Las lecturas sobre la clase "padre" aplican UNION ALL entre todas las tablas de la jerarquía.



Concrete Table Inheritance:

- Ventajas:
 - Cada tabla es auto contenida y no tiene campos irrelevantes.
 - Puede ser útil para otras aplicaciones que no consideran objetos ni/o herencia.
 - No hay joins en lectura de datos de una subclase.
 - El acceso a las subclases individualmente reparte la carga y reduce cuellos de botella.



Concrete Table Inheritance:

- Inconvenientes:
 - Las claves primarias pueden ser difíciles de manejar.
 - No se pueden utilizar relaciones de base de datos en clases abstractas.
 - En caso de refactorización de campos arriba o abajo de la jerarquía, se tiene que modificar las tablas, aunque menos que en class table inheritance.
 - Si se modifica un campo de superclase hay que cambiar cada tabla que tenga este campo porque los campos de superclase están duplicados en las tablas.
 - Una consulta sobre la superclase obliga a comprobar todas las tablas,
 lo que lleva a múltiples accesos a la base de datos.



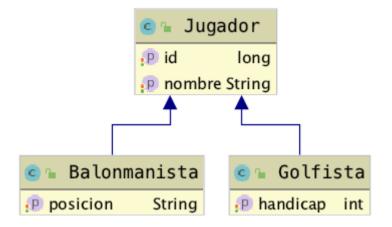
Mapped Superclass:

- En la estrategia concrete table inheritance puede que sea conveniente eliminar la jerarquía de la base de datos porque no hay claves ajenas implicadas.
 - Se cambia la anotación @Entity por @MappedSuperclass en la superclase.
 - Se hace que la superclase sea abstracta.
- No se pueden hacer consultas polimórficas.
- Esta variante mejora la eficiencia:
 - Escrituras en una sola tabla.
 - Lecturas sin joins.



Ejemplo:

- Jerarquía de jugadores de diferentes deportes.
- En cada paquete del ejemplo se utiliza una estrategia de implementación diferente.



Código en GitHub:



Buenas prácticas sobre herencia:

- Implementar herencia en BD es complicado. Se recomienda hacerlo solamente si los beneficios son mayores que los inconvenientes.
- Single table inheritance es recomendable si existen pocas clases en la jerarquía.
 - Sus operaciones tienen buen rendimiento.
 - Si hay soporte para disparadores se pueden controlar restricciones sobre datos.
- Class table inheritance es recomendable si hay muchas clases en la jerarquía y no son tan necesarias las consultas polimórficas.
 - Las consultas polimórficas no son eficientes.
- Concrete table inheritance es el método menos efectivo para consultas polimórficas.
 - Se puede aumentar la eficiencia con mapped superclasses.
- Las estrategias de implementación de herencia se pueden combinar.



- JDBC permite tomar el control sobre las sentencias SQL utilizadas.
 - Permite trabajar en comandos eficientes.
 - Requiere gran conocimiento de SQL.
 - Obliga a una implementación completa de la capa de persistencia.
- La utilización de ORMs ayuda a tratar con la "impedancia" de tablas vs objetos.
- Los ORM como Hibernate generan comandos SQL de manera automática.
- Permiten recopilar un grafo completo de entidades a través de un comando sencillo.
 - Pueden llevar a rendimiento poco eficiente si se desconoce su funcionamiento interno.
 - Too-much-fetching



- Es conveniente distinguir entre entidades y otros resultados de consultas.
- Una entidad es un dato que se hace persistente en la BD.
- Es habitual que haya consultas que producen resultados que no se corresponden exactamente con entidades. Fundamentalmente:
 - Subconjuntos de datos.
 - Consultas agregadas.
- Para trabajar con este tipo de situaciones se utilizan DTOs (Data Transfer Objects).
 - Son proyecciones que permiten aprovecharse del mecanismo de persistencia automático.
 - No son entidades.



- Un workaround típico cuando se trabaja con proyecciones de la BD es cargar un grafo de entidades y después filtrar en memoria.
- Las consultas sobre entidades no son la solución universal:
 - Si se utiliza un subconjunto de los datos, existe un desperdicio de recursos: memoria, ancho de banda, tiempo (recolector de basura), ...
 - Los resultados de las consultas sobre entidades son más difíciles de paginar, especialmente si tienen entidades asociadas.
 - Se aplican mecanismos de bloqueo y comprobación de cambios sobre los datos, que típicamente no se modifican en este tipo de consultas.
- Las consultas sobre entidades son útiles si es necesario modificar las entidades cargadas.
- Cargar más datos de los necesarios incrementa el tiempo de respuesta y desperdicia recursos.



- Las proyecciones DTO son ideales al trabajar con subconjuntos de datos, consultas de solo lectura o agregaciones.
- Las proyecciones DTO son type-safe.
- Los repositorios permiten la utilización de proyecciones DTO a través de JPQL y la utilización de constructores.
- Implementación en Hibernate con JPQL:
 - Se crea la clase DTO (no es una entidad).
 - Se crea una consulta ad hoc que devuelva campos que coincidan con la definición de la clase.
 - La consulta debe "invocar" al constructor del DTO.

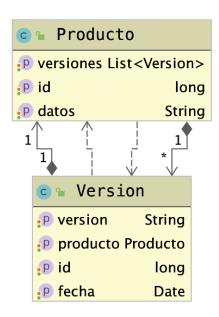


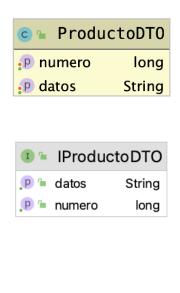
- Implementación en Hibernate con queries nativas.
 - El DTO debe ser un interfaz que solamente incluya los getters.
 - Se definen tantos elementos como campos sean necesarios.
 - La query nativa devolverá los atributos usando los nombres indicados en los getters del interfaz.
 - No es necesario utilizar todos los elementos declarados en el interfaz.



Ejemplo:

Producto y versión con proyecciones DTO.





Código en GitHub:

Gestión de concurrencia



- El acceso concurrente a bases de datos es muy común, y requiere una gestión eficiente.
- Las lecturas concurrentes no provocan reducción del rendimiento.
 - Salvo funciones de agregación bloqueantes.
- Las escrituras sí pueden provocar reducción de rendimiento.
- Transacciones: una transacción es un conjunto de operaciones que se ejecuta de manera atómica. Verifica las propiedades ACID
 - Atomicity (atomicidad): se ejecutan completamente o se deshacen completamente.
 - Consistency (consistencia): transición entre estados consistentes.
 - Isolation (aislamiento): no se afecta a otras transacciones.
 - Durability (persistencia): los cambios perduran.





Grado de aislamiento (Isolation level): ¡afecta a las lecturas!

- READ_UNCOMMITED: Lectura de valores escritos por otras transacciones que todavía no han finalizado (y podrían abortarse finalmente) (Dirty reads)
- READ_COMMITED: Si durante la transacción se lee la misma fila dos veces y esa fila es modificada por otra transacción entre medias se leen valores diferentes (Non-repeatable reads)
- REPEATABLE_READ: Si se hace una consulta y se obtienen unas filas y otra transacción añade nuevas filas y se vuelve a hacer la misma consulta, aparecen filas nuevas (*Phantom reads*)
- SERIALIZABLE: Las transacciones están aisladas entre sí. Su comportamiento es como si se ejecutaran secuencialmente.

Gestión de concurrencia



Spring Data

- Anotación @Transactional hace que un método se ejecute como una sola transacción.
 - Solamente si el método anotado se invoca desde otro bean.
 - https://codete.com/blog/5-common-spring-transactional-pitfalls/
- Tanto save como saveAll están anotados como @Transactional
 - Afecta a rendimiento tanto del propio almacenamiento de datos como de la interacción con otros accesos concurrentes.
- Conviene repartir el trabajo en varias hebras.

Gestión de concurrencia



Ejemplo:

- Inserción de 10.000 productos
- Bucle save vs saveAll
- Concurrencia 1: 4 hebras escribiendo a la vez
 - Bucle save vs saveAll y conteo concurrentes.
- Concurrencia 2: 4 hebras escribiendo a la vez
 - Mismo código en dos métodos, uno anotado como @Transactional.
 - Se usa un bean diferente para que @Transactional funcione.

Código en GitHub:

https://github.com/MasterCloudApps/2.3.Persistencia-y-analisis-de-datos/tree/master/tema1/ejemplo7_springdata_concurrencia